Assignment 3 – Nhiệm vụ A: Hồi quy tuyến tính

A1 – Mô hình

Đề bài. Viết mô hình hồi quy tuyến tính có nhiễu Gauss và nêu rõ giả thiết về nhiễu.

Lời giải.

$$y_n = \phi(x_n)^\top \theta + \varepsilon_n,$$
$$\varepsilon_n \sim \mathcal{N}(0, \sigma^2),$$
$$n = 1, \dots, N,$$
$$\Longleftrightarrow$$
$$p(y_n \mid x_n, \theta) = \mathcal{N}\big(y_n \mid \phi(x_n)^\top \theta,\ \sigma^2\big). \qquad (1)$$

Ở đây $\theta = (\theta_0, \theta_1)^\top \in \mathbb{R}^2$ (hệ số chặn và hệ số góc). Giả thiết về nhiễu: (i) $\mathrm{E}[\varepsilon_n] = 0$; (ii) phương sai không đổi σ^2 (đồng phương sai); (iii) phân phối Gauss; (iv) $\varepsilon_1, \dots, \varepsilon_N$ độc lập, do đó $p(y \mid X, \theta) = \prod_n p(y_n \mid x_n, \theta)$. Các đầu vào x_n được coi là hằng số đã biết.

A2 – Cực đại hợp lý ⇒ bình phương tối thiểu ⇒ θ_{ML} (làm tay)

Đề bài. Xuất phát từ $p(y \mid X, \theta) = \prod_n N(y_n \mid \varphi(x_n)^\top \theta, \sigma^2)$, chứng minh cực đại hoá hàm hợp lý tương đương cực tiểu hoá tổng bình phương sai số, rồi suy ra $\theta_{\mathrm{ML}} = (\Phi^\top \Phi)^{-1} \Phi^\top y$.

Kích thước. $y \in \mathbb{R}^{N \times 1}$, $\Phi = [\varphi(x_1)^\top; \dots; \varphi(x_N)^\top] \in \mathbb{R}^{N \times 2}$, $\theta \in \mathbb{R}^{2 \times 1}$, $\Phi^\top \Phi \in \mathbb{R}^{2 \times 2}$, $\Phi^\top y \in \mathbb{R}^{2 \times 1}$.

Lời giải. Bước 1 – logarit hàm hợp lý. Vì log đồng biến, cực đại hoá p tương đương cực đại hoá log p:

$$\log p(y \mid X, \theta)$$
$$= \sum_{n=1}^{N} \log \left[\frac{1}{\sqrt{2\pi\sigma^2}} \exp\Big(- \frac{(y_n - \phi(x_n)^\top \theta)^2}{2\sigma^2} \Big) \right]$$
$$= -\frac{N}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{n=1}^{N} \big(y_n - \phi(x_n)^\top \theta\big)^2.$$

Bước 2 – tương đương. Số hạng đầu không phụ thuộc θ và $1/2\sigma^2 > 0$, do đó

$$\arg\max_\theta \log p(y \mid X, \theta) = \arg\min_\theta \sum_n \big(y_n - \phi(x_n)^\top \theta\big)^2$$
$$= \arg\min_\theta \ \|y - \Phi\theta\|^2.$$

Bước 3 – gradient (quy ước vectơ hàng). Với $L(\theta) = \|y - \Phi\theta\|^2 = (y - \Phi\theta)^\top (y - \Phi\theta)$,

$$\frac{\partial \mathcal{L}}{\partial \theta} = -2\,(y - \Phi\theta)^\top \Phi \in \mathbb{R}^{1 \times 2}.$$

Bước 4 – điều kiện dừng. Cho gradient bằng 0: $(y - \Phi\theta)^\top \Phi = 0 \Leftrightarrow y^\top \Phi = \theta^\top \Phi^\top \Phi$; chuyển vị ta được *phương trình chuẩn tắc*

$$\Phi^\top \Phi\, \theta = \Phi^\top y \implies \theta_{ML} = (\Phi^\top \Phi)^{-1} \Phi^\top y, \qquad (2)$$

tồn tại khi $\mathrm{rank}\Phi = 2$ (để $\Phi^\top \Phi$ khả nghịch).

Bước 5 – đây là cực tiểu. Ma trận Hesse của L là $2\Phi^T\Phi$ và $v^T\Phi^T\Phi v = \|\Phi v\|^2 \geq 0$; vậy L là hàm lồi, điểm dừng là cực tiểu toàn cục, và duy nhất khi $\Phi^T\Phi \succ 0$.

A3 – Tính tay trên 5 mẫu đầu

Đề bài. Với $\varphi(x) = [1, x]^T$ và 5 mẫu đầu, tính θ_{ML} và vectơ phần dư, kiểm tra phần dư trực giao với các cột của Φ và giải thích ý nghĩa hình học.

Dữ liệu (năm dòng đầu, cm): $x = (1.4, 1.4, 1.3, 1.5, 1.4)^T$ (chiều dài cánh hoa), $y = (5.1, 4.9, 4.7, 4.6, 5.0)^T$ (chiều dài đài hoa),

$$\Phi = \begin{pmatrix} 1 & 1.4 \\ 1 & 1.4 \\ 1 & 1.3 \\ 1 & 1.5 \\ 1 & 1.4 \end{pmatrix}$$

(cỡ 5×2).

Lời giải. Bước 1 – các tổng. $\sum x = 1.4 + 1.4 + 1.3 + 1.5 + 1.4 = 7.0$; $\sum x^2 = 1.96 + 1.96 + 1.69 + 2.25 + 1.96 = 9.82$; $\sum y = 5.1 + 4.9 + 4.7 + 4.6 + 5.0 = 24.3$; $\sum xy = 7.14 + 6.86 + 6.11 + 6.90 + 7.00 = 34.01$.

$$\Phi^\top\Phi = \begin{pmatrix} 5 & 7.0 \\ 7.0 & 9.82 \end{pmatrix}, \qquad \Phi^\top y = \begin{pmatrix} 24.3 \\ 34.01 \end{pmatrix}.$$

Bước 2 – ma trận nghịch đảo. $\det = 5 \cdot 9.82 - 7.0^2 = 49.1 - 49 = 0.1$, nên

$$(\Phi^\top\Phi)^{-1} = \frac{1}{0.1}\begin{pmatrix} 9.82 & -7.0 \\ -7.0 & 5 \end{pmatrix} = 10\begin{pmatrix} 9.82 & -7.0 \\ -7.0 & 5 \end{pmatrix}$$

.

Bước 3 – nghiệm.

$$\theta_0 = 10\,(9.82 \cdot 24.3 - 7.0 \cdot 34.01) = 10\,(238.626 - 238.07) = 5.56,$$
$$\theta_1 = 10\,(-7.0 \cdot 24.3 + 5 \cdot 34.01) = 10\,(-170.1 + 170.05) = -0.5.$$

Vậy $\theta_{ML} = (5.56, -0.5)^T$ và giá trị khớp là $\hat{y} = 5.56 - 0.5x = (4.86, 4.86, 4.91, 4.81, 4.86)^T$.

Bước 4 – phần dư. $r = y - \hat{y} = (0.24, 0.04, -0.21, -0.21, 0.14)^T$.

Bước 5 – tính trực giao. Cột 1 của Φ là $\mathbf{1}$: $\mathbf{1}^T r = 0.24 + 0.04 - 0.21 - 0.21 + 0.14 = 0$. Cột 2 là x:

$$x^\top r = 1.4(0.24) + 1.4(0.04) + 1.3(-0.21) + 1.5(-0.21) + 1.4(0.14) = 0.336 + 0.056 - 0.273 - 0.315 + 0.196 = 0.$$

Do đó $\Phi^T r = 0$: phần dư trực giao với cả hai cột của Φ (đã kiểm tra bằng số trong notebook: $|\Phi^T r| < 10^{-14}$).

Ý nghĩa hình học. Các cột của Φ sinh ra một không gian con hai chiều $U = \text{col}(\Phi) \subset \mathbb{R}^5$. Vectơ $\hat{y} = \Phi\theta_{ML}$ là *hình chiếu trực giao* của y lên U (điểm của U gần y nhất), và $\Phi^T r = 0$ chính là phát biểu $r \perp U$ – phương trình chuẩn tắc (2) viết lại thành $\Phi^T(y - \Phi\theta) = 0$. Điều kiện thứ nhất $\mathbf{1}^T r = 0$ nghĩa là tổng các phần dư bằng 0 vì mô hình có hệ số chặn.

A4 – Cài đặt trên toàn bộ dữ liệu

Đề bài. Cài đặt θ_{ML} bằng công thức ở A2 (không dùng `LinearRegression`) trên toàn bộ dữ liệu, đối chiếu với `sklearn` và báo cáo sai số.

Lời giải. $\Phi \in \mathbb{R}^{150 \times 2}$, $\theta = solve(\Phi^T\Phi, \Phi^T y)$. Kết quả (cm):

	hệ số chặn θ_0 (cm)	hệ số góc θ_1 (cm/cm)	RMSE (cm)
công thức của nhóm	4.3066	0.4089	0.4044
`sklearn LinearRegression`	4.3066	0.4089	0.4044
sai khác tuyệt đối	$3.6e-15$	$5.6e-17$	–

Sai khác tuyệt đối lớn nhất giữa hai bộ giá trị dự đoán là $3.6e-15$ cm, tức bằng độ chính xác máy.

A5 – Ước lượng MAP (làm tay)

Đề bài. Với tiên nghiệm $\theta \sim N(0, b^2 I)$, suy ra $\theta_{\text{MAP}} = (\Phi^{\mathrm{T}}\Phi + (\sigma^2/b^2)I)^{-1}\Phi^{\mathrm{T}}y$ và chứng minh $\theta_{\text{MAP}} \to \theta_{\text{ML}}$ khi $b \to \infty$, $\theta_{\text{MAP}} \to 0$ khi $b \to 0$.

Lời giải. Bước 1 – hậu nghiệm. Theo công thức Bayes, $p(\theta \mid X, y) \propto p(y \mid X, \theta)\, p(\theta)$, với $p(\theta) = N(0, b^2 I) \propto \exp(-(1/2b^2)\|\theta\|^2)$. Khi đó

$$-\log p(\theta \mid X, y) = \tfrac{1}{2\sigma^2}\|y - \Phi\theta\|^2 + \tfrac{1}{2b^2}\|\theta\|^2 + \text{hằng số}.$$

Bước 2 – gradient. $(\partial)/(\partial\theta)[-\log p] = -(1/\sigma^2)(y - \Phi\theta)^{\mathrm{T}}\Phi + (1/b^2)\theta^{\mathrm{T}}$.

Bước 3 – điều kiện dừng. Cho bằng 0 và nhân với σ^2: $-(y - \Phi\theta)^{\mathrm{T}}\Phi + (\sigma^2/b^2)\theta^{\mathrm{T}} = 0 \Leftrightarrow \theta^{\mathrm{T}}(\Phi^{\mathrm{T}}\Phi + (\sigma^2/b^2)I) = y^{\mathrm{T}}\Phi$. Chuyển vị (ma trận đối xứng):

$$\theta_{MAP} = \left(\Phi^\top \Phi + \lambda I\right)^{-1} \Phi^\top y, \qquad \lambda := \frac{\sigma^2}{b^2} > 0. \qquad (3)$$

Ma trận này luôn khả nghịch: $\Phi^{\mathrm{T}}\Phi \succcurlyeq 0$ và $\lambda I \succ 0$ cho $v^{\mathrm{T}}(\Phi^{\mathrm{T}}\Phi + \lambda I)v \geq \lambda\|v\|^2 > 0$. Tương đương, $\theta_{\text{MAP}} = \arg\min \|y - \Phi\theta\|^2 + \lambda\|\theta\|^2$ (hồi quy Ridge).

Bước 4 – $b \to \infty$. Khi đó $\lambda = \sigma^2/b^2 \to 0$. Nếu $\Phi^{\mathrm{T}}\Phi$ khả nghịch thì phép lấy nghịch đảo ma trận liên tục tại $\Phi^{\mathrm{T}}\Phi$, nên $(\Phi^{\mathrm{T}}\Phi + \lambda I)^{-1} \to (\Phi^{\mathrm{T}}\Phi)^{-1}$ và $\theta_{\text{MAP}} \to (\Phi^{\mathrm{T}}\Phi)^{-1}\Phi^{\mathrm{T}}y = \theta_{\text{ML}}$. (Trực giác: tiên nghiệm rộng vô hạn không mang thông tin.)

Bước 5 – $b \to 0$. Khi đó $\lambda \to \infty$. Với mọi v, $\|(\Phi^{\mathrm{T}}\Phi + \lambda I)v\| \geq \lambda\|v\|$, suy ra $\|(\Phi^{\mathrm{T}}\Phi + \lambda I)^{-1}\|_2 \leq 1/\lambda$ và

$$\|\theta_{MAP}\| \leq \frac{\|\Phi^\top y\|}{\lambda} \xrightarrow[\lambda\to\infty]{} 0.$$

(Trực giác: tiên nghiệm hẹp vô hạn ép $\theta = 0$ bất kể dữ liệu.)

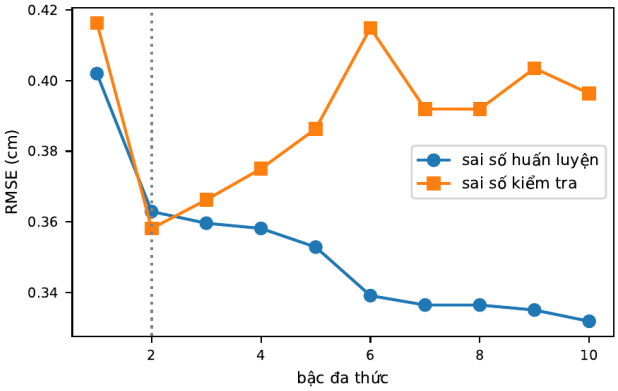
A6 – Đa thức bậc 1–10 và hiện tượng quá khớp

Đề bài. Chia dữ liệu 70/30, khớp đa thức bậc 1, …, 10, vẽ sai số huấn luyện và kiểm tra theo bậc, chỉ ra bậc bắt đầu quá khớp và giải thích bằng A5 vì sao tiên nghiệm giúp hạn chế hiện tượng này.

Lời giải. 150 mẫu được xáo trộn và chia với hạt giống cố định: 105 mẫu huấn luyện và 45 mẫu kiểm tra. Đầu vào được chuẩn hoá bằng trung bình huấn luyện (3.900 cm) và độ lệch chuẩn huấn luyện (1.715 cm) *trước* khi lấy luỹ thừa (nếu không $\Phi^{\mathrm{T}}\Phi$ điều kiện rất xấu). Với bậc d, $\varphi(x) = [1, z, z^2, \ldots, z^d]^{\mathrm{T}}$, $\Phi \in \mathbb{R}^{105 \times (d+1)}$ và θ lấy từ phương trình chuẩn tắc (`solve`). Sai số = RMSE = $\sqrt{(1/n)\sum(y_n - \hat{y}_n)^2}$ tính bằng cm.

bậc d	RMSE huấn luyện (cm)	RMSE kiểm tra (cm)	cond($\Phi^{\mathrm{T}}\Phi$)	$\|\theta\|$
1	0.4020	0.4163	1.0e+00	5.93
2	0.3629	0.3581	1.0e+01	5.73
3	0.3596	0.3662	1.0e+02	5.76
4	0.3581	0.3750	3.6e+02	5.75

bậc d	RMSE huấn luyện (cm)	RMSE kiểm tra (cm)	cond($\Phi^T\Phi$)	$\|\theta\|$
5	0.3528	0.3863	2.4e+03	5.73
6	0.3391	0.4149	2.0e+04	6.04
7	0.3364	0.3920	9.6e+04	6.15
8	0.3364	0.3919	6.2e+05	6.15
9	0.3350	0.4035	6.1e+06	7.15
10	0.3318	0.3963	5.2e+07	8.48



Hình 1. RMSE (cm) huấn luyện và kiểm tra theo bậc đa thức. Đường chấm đánh dấu bậc có sai số kiểm tra nhỏ nhất.

Quá khớp bắt đầu ở đâu. Sai số huấn luyện không bao giờ tăng, đi từ 0.4020 (bậc 1) xuống 0.3318 (bậc 10). Sai số kiểm tra nhỏ nhất ở bậc 2 (0.3581 cm) và lớn hơn từ bậc 3 trở đi (0.3662 cm ở $d = 3$, 0.3963 cm ở $d = 10$) trong khi sai số huấn luyện vẫn giảm: **quá khớp bắt đầu ở bậc 3**, mô hình bắt đầu khớp nhiễu. Hiệu ứng ở mức vừa phải (đường sai số kiểm tra không đơn điệu, chỉ có 45 mẫu kiểm tra) nhưng thể hiện rõ ở khoảng cách mở rộng giữa hai đường. Đồng thời điều kiện số xấu đi (cond tăng từ 1 lên $5.2e + 07$) và $\|\theta\|$ tăng từ 5.73 lên 8.48.

Vì sao tiên nghiệm giúp ích (theo ngôn ngữ của A5). Nghiệm MAP cực tiểu hoá $\|y - \Phi\theta\|^2 + \lambda\|\theta\|^2$ với $\lambda = \sigma^2/b^2$. Tiên nghiệm $N(0, b^2 I)$ nói rằng hệ số lớn là khó xảy ra, nên nó phạt đúng các đường cong đa thức bậc cao uốn lượn (cần $\|\theta\|$ lớn). Nó cũng làm ma trận $\Phi^T\Phi + \lambda I$ có điều kiện tốt (giá trị riêng nhỏ nhất $\geq \lambda$). b nhỏ (λ lớn) co mô hình về 0 (khớp thiếu); b rất lớn cho lại θ_{ML} (quá khớp): λ điều khiển sự đánh đổi độ chệch – phương sai.

Nhiệm vụ B · Phân tích thành phần chính (PCA)

B1. Tính ma trận hiệp phương sai

$$N = 3, \qquad x_1 = \begin{pmatrix} 5 \\ 3 \\ 4 \end{pmatrix}, \quad x_2 = \begin{pmatrix} 2 \\ 0 \\ 5 \end{pmatrix}, \quad x_3 = \begin{pmatrix} 2 \\ 3 \\ 3 \end{pmatrix}.$$

$$\bar{x} = \frac{1}{3} \sum_{i=1}^{3} x_i = \frac{1}{3} \begin{pmatrix} 5+2+2 \\ 3+0+3 \\ 4+5+3 \end{pmatrix} = \begin{pmatrix} 3 \\ 2 \\ 4 \end{pmatrix}.$$

Vectơ trung bình xác định tâm của ba điểm dữ liệu theo từng đặc trưng.

$$\tilde{x}_1 = x_1 - \bar{x} = \begin{pmatrix} 2 \\ 1 \\ 0 \end{pmatrix}, \quad \tilde{x}_2 = x_2 - \bar{x} = \begin{pmatrix} -1 \\ -2 \\ 1 \end{pmatrix},$$

$$\tilde{x}_3 = x_3 - \bar{x} = \begin{pmatrix} -1 \\ 1 \\ -1 \end{pmatrix}.$$

$$\sum_{i=1}^{3} \tilde{x}_i = \begin{pmatrix} 2 \\ 1 \\ 0 \end{pmatrix} + \begin{pmatrix} -1 \\ -2 \\ 1 \end{pmatrix} + \begin{pmatrix} -1 \\ 1 \\ -1 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \\ 0 \end{pmatrix}.$$

Tổng bằng vectơ không xác nhận rằng dữ liệu sau tâm hóa có giá trị trung bình bằng 0.

$$S = \frac{1}{N} \sum_{i=1}^{N} \tilde{x}_i \tilde{x}_i^{\top}$$

$$= \frac{1}{3} \left[\begin{pmatrix} 4 & 2 & 0 \\ 2 & 1 & 0 \\ 0 & 0 & 0 \end{pmatrix} + \begin{pmatrix} 1 & 2 & -1 \\ 2 & 4 & -2 \\ -1 & -2 & 1 \end{pmatrix} + \begin{pmatrix} 1 & -1 & 1 \\ -1 & 1 & -1 \\ 1 & -1 & 1 \end{pmatrix} \right]$$

$$= \frac{1}{3} \begin{pmatrix} 6 & 3 & 0 \\ 3 & 6 & -3 \\ 0 & -3 & 2 \end{pmatrix} = \boxed{\begin{pmatrix} 2 & 1 & 0 \\ 1 & 2 & -1 \\ 0 & -1 & \frac{2}{3} \end{pmatrix}}.$$

Ma trận hiệp phương sai là trung bình của các tích ngoài; mỗi phần tử biểu diễn mức biến thiên đồng thời giữa hai đặc trưng.

$$S^{\top} = \begin{pmatrix} 2 & 1 & 0 \\ 1 & 2 & -1 \\ 0 & -1 & \frac{2}{3} \end{pmatrix} = S.$$

Vì $S^{\top} = S$, ma trận S đối xứng.

B2. Giá trị riêng và thành phần chính thứ nhất

$$A = S_{1:2,\,1:2} = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}.$$

$$\begin{aligned} \det(A - \lambda I) &= 0 \\ \det\begin{pmatrix} 2-\lambda & 1 \\ 1 & 2-\lambda \end{pmatrix} &= 0 \\ (2-\lambda)^2 - 1 &= 0 \\ \lambda^2 - 4\lambda + 3 &= 0 \\ (\lambda - 3)(\lambda - 1) &= 0. \end{aligned}$$

Giải phương trình đặc trưng để tìm các giá trị riêng của ma trận hiệp phương sai con đã chọn.

$$\boxed{\lambda_1 = 3, \qquad \lambda_2 = 1, \qquad \lambda_1 > \lambda_2.}$$

$$\begin{aligned} (A - \lambda_1 I)v = 0 &\iff \begin{pmatrix} -1 & 1 \\ 1 & -1 \end{pmatrix}\begin{pmatrix} v_1 \\ v_2 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \\ &\iff -v_1 + v_2 = 0 \iff v_2 = v_1. \end{aligned}$$

$$v = \begin{pmatrix} 1 \\ 1 \end{pmatrix}, \qquad \|v\|_2 = \sqrt{2}, \qquad u_1 = \frac{v}{\|v\|_2} = \frac{1}{\sqrt{2}}\begin{pmatrix} 1 \\ 1 \end{pmatrix} \approx \begin{pmatrix} 0.7071 \\ 0.7071 \end{pmatrix}.$$

Vectơ riêng ứng với giá trị riêng lớn nhất xác định hướng của thành phần chính thứ nhất (PC1).

$$\operatorname{tr}(A) = \lambda_1 + \lambda_2 = 3 + 1 = 4, \qquad \frac{\lambda_1}{\lambda_1 + \lambda_2} \times 100\% = \frac{3}{4} \times 100\% = \boxed{75\%}.$$

PC1 giữ lại 75% phương sai của ma trận A; nếu xét toàn bộ ma trận S, tỷ lệ tương ứng là $\frac{3}{14/3} = \frac{9}{14} \approx 64{,}29\%$.

B3. PCA trên tập dữ liệu Iris đã chuẩn hoá

Dữ liệu: $N = 150$ mẫu, $d = 4$ đặc trưng (đơn vị cm). *Chuẩn hoá từng đặc trưng về trung bình 0 và phương sai 1 trước khi thực hiện PCA.*

$$z_{nj} = \frac{x_{nj} - \mu_j}{s_j}, \qquad \mu_j = \frac{1}{N}\sum_{n=1}^{N} x_{nj}, \qquad s_j = \sqrt{\frac{1}{N}\sum_{n=1}^{N}(x_{nj} - \mu_j)^2}.$$

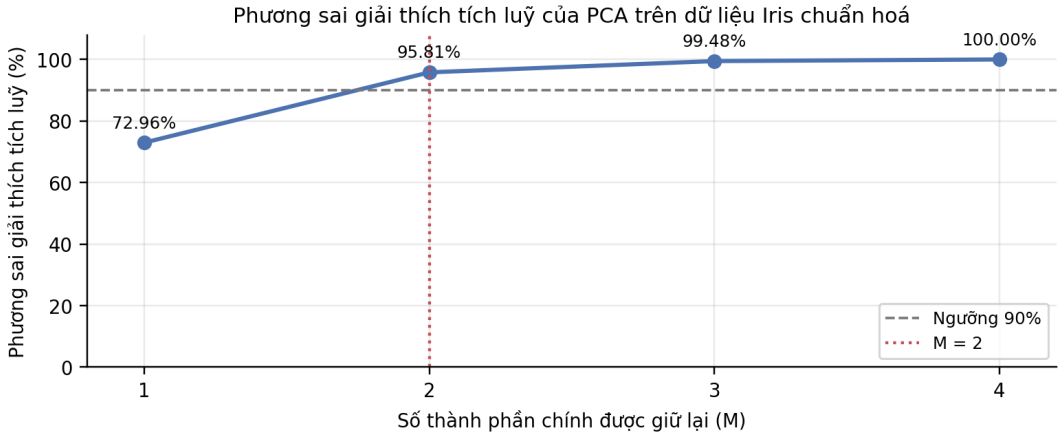
	Đài hoa dài	Đài hoa rộng	Cánh hoa dài	Cánh hoa rộng
μ_j	5.8433	3.0573	3.7580	1.1993
s_j	0.8253	0.4344	1.7594	0.7597

Ma trận hiệp phương sai của dữ liệu chuẩn hoá (chia cho N) chính là ma trận tương quan.

$$Z \in \mathbb{R}^{150\times 4}, \qquad S = \frac{1}{N} Z^\top Z = V \Lambda V^\top, \qquad \lambda_1 \geq \lambda_2 \geq \lambda_3 \geq \lambda_4.$$

Thành phần	λ_j	Tỷ lệ phương sai	Tích luỹ
PC1	2.918498	72.9624%	72.9624%
PC2	0.914030	22.8508%	95.8132%
PC3	0.146757	3.6689%	99.4821%
PC4	0.020715	0.5179%	100.0000%

$$\mathrm{EVR}_j = \frac{\lambda_j}{\sum_{k=1}^{4} \lambda_k}, \qquad \sum_{j=1}^{4} \lambda_j = \mathrm{tr}(S) = 4.$$



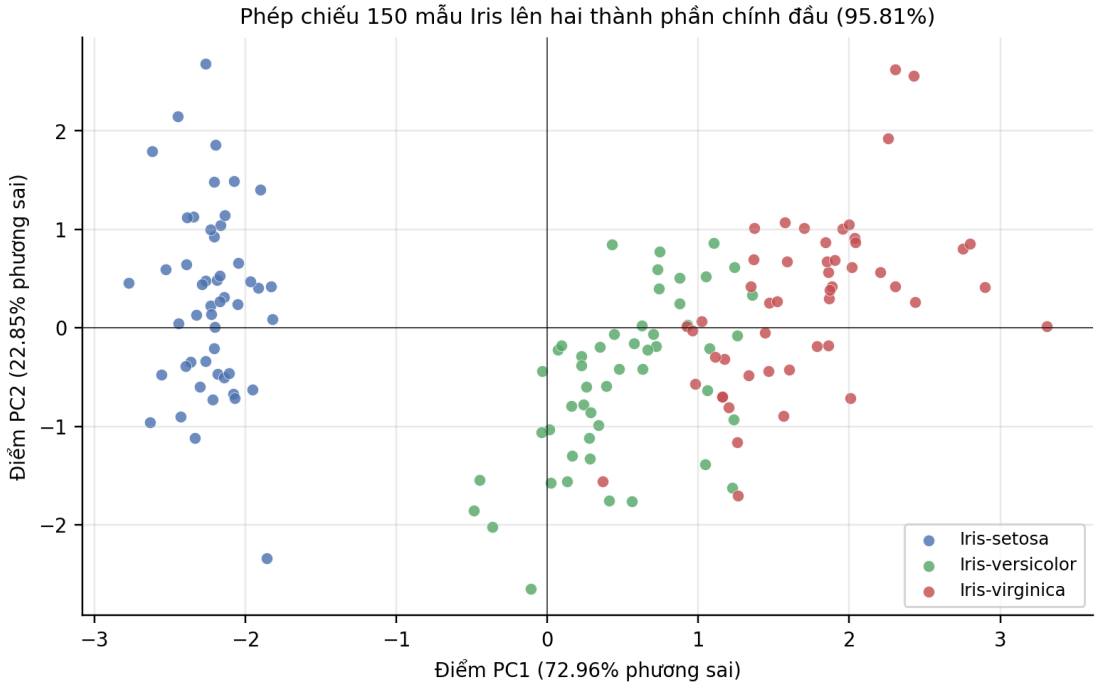
$$M = \min\left\{ m : \sum_{j=1}^{m} \mathrm{EVR}_j \geq 0.90 \right\} = 2, \qquad \mathrm{EVR}_{1:2} = 95.8132\%.$$

Hai thành phần chính đầu là số thành phần tối thiểu để giữ ít nhất 90% phương sai.

B4. Chiếu dữ liệu lên hai thành phần chính đầu

Dùng hai vectơ riêng đầu $V_2 = [v_1\ v_2]$ để biến đổi dữ liệu chuẩn hoá sang toạ độ PCA.

$$T = ZV_2 \in \mathbb{R}^{150\times 2}, \qquad T_{n1} = z_n^\top v_1, \quad T_{n2} = z_n^\top v_2.$$



PC1 và PC2 giữ lại tổng cộng 95.8132% phương sai; màu sắc chỉ biểu thị nhãn loài, không được dùng để tính PCA.

Hệ số tải (loadings):

Đặc trưng	PC1	PC2
Chiều dài đài hoa	0.5211	0.3774
Chiều rộng đài hoa	-0.2693	0.9233
Chiều dài cánh hoa	0.5804	0.0245
Chiều rộng cánh hoa	0.5649	0.0669

Nhận xét:

- Iris-setosa tách biệt rõ khỏi hai loài còn lại theo trục PC1.
- Iris-versicolor và Iris-virginica nằm gần nhau hơn và có vùng chồng lấn nhẹ.
- PC1 chủ yếu phản ánh kích thước tổng thể của hoa; PC2 chịu ảnh hưởng lớn nhất từ chiều rộng đài hoa.

Hai điểm số PC1 và PC2 không tương quan; phương sai của chúng lần lượt bằng λ_1 và λ_2.

$$\mathrm{corr}(T_{:,1}, T_{:,2}) \approx 0, \qquad \mathrm{Var}(T_{:,1}, T_{:,2}) = (2.918498,\ 0.914030).$$

B5. Thực hiện PCA bằng phân rã giá trị kỳ dị (SVD)

Thay vì chéo hoá trực tiếp S, phân rã ma trận dữ liệu chuẩn hoá Z bằng SVD.

$$Z = U\Sigma V^\top, \qquad U^\top U = I.$$

$$\begin{aligned} S &= \frac{1}{N} Z^\top Z = \frac{1}{N} V\Sigma^\top U^\top U\Sigma V^\top \\ &= V\left(\frac{\Sigma^\top\Sigma}{N}\right)V^\top. \end{aligned}$$

$$\boxed{\lambda_j = \frac{\sigma_j^2}{N}} \qquad (j = 1, \dots, 4).$$

Các vectơ kỳ dị phải của Z chính là các vectơ riêng của S (sai khác dấu có thể xảy ra).

Thành phần	σ_j	σ_j^2/N	λ_j từ S
PC1	20.923066	2.918498	2.918498
PC2	11.709166	0.914030	0.914030
PC3	4.691858	0.146757	0.146757
PC4	1.762732	0.020715	0.020715

$$\max_j \left|\frac{\sigma_j^2}{N} - \lambda_j\right| = 1.33 \times 10^{-15}, \qquad M_{90\%} = 2.$$

Hai cách cho cùng giá trị riêng, tỷ lệ phương sai và số thành phần cần giữ; sai khác ở mức sai số dấu phẩy động.

Độ ổn định số học.

$$\kappa(Z^\top Z) = \kappa(Z)^2, \qquad \kappa(Z) = 11.87, \quad \kappa(Z^\top Z) = 140.89.$$

Tạo $Z^\top Z$ làm bình phương số điều kiện, khiến các giá trị kỳ dị nhỏ dễ mất chính xác khi làm tròn.

Với ma trận Läuchli và $\varepsilon = 10^{-9}$:

$$A = \begin{pmatrix} 1 & 1 & 1 \\ \varepsilon & 0 & 0 \\ 0 & \varepsilon & 0 \\ 0 & 0 & \varepsilon \end{pmatrix}, \qquad \sigma(A) \approx (1.732, 10^{-9}, 10^{-9}).$$

Phương pháp	Sai số tương đối lớn nhất	Kết quả
SVD trực tiếp trên A	6.20×10^{-16}	Giữ được hai giá trị 10^{-9}
Chéo hoá $A^\top A$	1.70	$A^\top A$ bị làm tròn thành ma trận toàn số 1

SVD ổn định hơn vì làm việc trực tiếp với Z (hoặc A), không phải bình phương các giá trị kỳ dị qua ma trận Gram.

Assignment 3 – Nhiệm vụ C: Phân loại bằng SVM

MAI391 – Toán cho Học máy | Chương 12

Dữ liệu: Iris (tiếp nối Assignment 1). Nhiệm vụ A (hồi quy) và B (PCA) không ảnh hưởng trực tiếp đến C. C dùng hai đặc trưng liên tục + nhãn nhị phân tạo từ dữ liệu.

C1 – Tạo nhãn nhị phân và giữ hai đặc trưng

Đề bài. Tạo nhãn nhị phân từ dữ liệu (ví dụ biến mục tiêu lớn/nhỏ hơn trung vị), giữ lại hai đặc trưng để bài toán nằm trong mặt phẳng.

Lời giải. Chọn petal length và petal width vì cặp này tách lớp Setosa khỏi hai lớp còn lại rõ nhất trên Iris (sepal length/width chồng chéo nhiều hơn, hình SVM kém trực quan).

Nhãn: $y = +1$ nếu class = Iris-setosa, $y = -1$ nếu versicolor hoặc virginica. Chuẩn hoá StandardScaler (mean=0, std=1) trước khi huấn luyện SVM.

Kết quả: N = 150, số mẫu +1 = 50, số mẫu −1 = 100. X shape = (150, 2).

C2 – Siêu phẳng lề cực đại cho hai điểm (làm tay)

Đề bài. Cho $x_1 = (1, 1)$, $y_1 = +1$ và $x_2 = (-1, -1)$, $y_2 = -1$. Tìm siêu phẳng lề cực đại, giá trị lề và các vectơ hỗ trợ.

Lời giải (đủ bước).

Bước 1. Hai điểm đối xứng qua gốc → biên đi qua gốc ($b = 0$), pháp tuyến cùng hướng $x_1 - x_2 = (2, 2)$. Chọn hướng $w \parallel (1, 1)$.

Bước 2. Điều kiện lề cứng: $y_n(w^T x_n + b) \geq 1$, đẳng thức tại support vector. Với $b = 0$:

$$y_1 w^T x_1 = w_1 + w_2 = 1.$$

Đặt $w = t(1, 1) \Rightarrow 2t = 1 \Rightarrow t = 1/2$.

$$w^* = [1/2, 1/2]^T, b^* = 0.$$

Bước 3 – Lề.

$$\text{margin} = 2 / \|w\| = 2 / \sqrt{(1/2)} = 2\sqrt{2} \approx 2.8284.$$

Bước 4 – Support vectors. Cả hai điểm thoả $y_n(w^T x_n + b) = 1 \rightarrow x_1$ và x_2 đều là vectơ hỗ trợ.

Kiểm chứng số (notebook): $y_1(w \cdot x_1 + b) = 1.0$, $y_2(w \cdot x_2 + b) = 1.0$, $\|w\| = 0.7071$, margin = 2.8284.

C3 – Vai trò hình học của w và b

Đề bài. Giải thích bằng hình học vai trò của vectơ pháp tuyến w và độ chệch b.

w (pháp tuyến): hướng của w xác định hướng biên quyết định (biên vuông góc với w). Xoay w → biên xoay theo. Độ lớn $\|w\|$ liên hệ nghịch với độ rộng lề: margin = $2/\|w\|$. Tăng $\|w\|$ → lề hẹp lại.

b (độ chệch): dịch biên song song với chính nó, không đổi hướng và không đổi độ rộng lề (khi $\|w\|$ cố định). Tăng b → biên dịch về phía ngược hướng w; giảm b → dịch theo hướng w.

Tóm lại: w điều khiển hướng + độ rộng lề; b điều khiển vị trí song song của biên.

C4 – SVM tuyến tính với C ∈ {0.01; 1; 100}

Đề bài. Huấn luyện SVM tuyến tính trên dữ liệu C1 với ba giá trị C. Vẽ biên và lề. Mô tả ảnh hưởng của C tới số điểm vi phạm lề và độ rộng lề.

Lời giải. Dùng sklearn.svm.SVC(kernel='linear', C=...). Biên: $w^T x + b = 0$; hai đường lề: $= \pm 1$. Kết quả từ notebook:

C	#SV	#vi phạm lề	$\|w\|$	margin = $2/\|w\|$
0.01	80	77	0.7939	2.5191
1	5	3	1.7886	1.1182
100	2	0	1.9372	1.0324

Ảnh hưởng của C:

• C = 0.01 (nhỏ): lề rộng (margin ≈ 2.52), nhiều support vector (80) và nhiều vi phạm lề (77). Mô hình ưu tiên margin lớn, chấp nhận sai sót trên tập huấn luyện.

• C = 1: cân bằng — margin ≈ 1.12, chỉ 5 SV và 3 vi phạm.

• C = 100 (lớn): lề hẹp hơn (margin ≈ 1.03), chỉ 2 SV, 0 vi phạm. Ưu tiên phân loại đúng mọi điểm huấn luyện; trên Iris (Setosa vs rest) dữ liệu gần như tách hoàn toàn nên biên ổn định.

Quy luật: C tăng → ‖w‖ tăng → margin giảm; số vi phạm lề và số SV giảm.

C5 – Dữ liệu không khả tách tuyến tính (XOR)

Đề bài. Chỉ ra trường hợp không khả tách tuyến tính, chứng minh bằng bao lồi, rồi chỉ một ánh xạ đặc trưng làm dữ liệu khả tách.

Dữ liệu XOR:

$$x_1=(0,0)\ y_1=-1;\ x_2=(1,1)\ y_2=-1;\ x_3=(0,1)\ y_3=+1;\ x_4=(1,0)\ y_4=+1.$$

Chứng minh bằng bao lồi. Bao lồi lớp +1 là đoạn [(0,1),(1,0)], chứa điểm giữa (0.5, 0.5). Bao lồi lớp −1 là đoạn [(0,0),(1,1)], cũng chứa (0.5, 0.5). Hai bao lồi giao nhau. Định lý tách siêu phẳng: chỉ hai tập lồi rời nhau mới tách được bằng siêu phẳng. Vì bao lồi giao nhau → không tồn tại siêu phẳng phân tách.

Ánh xạ đặc trưng. $\varphi(x_1, x_2) = (x_1, x_2, x_1x_2) \in \mathbb{R}^3$. Trong không gian 3D, mặt $z = 0.5$ (tức $x_1x_2 = 0.5$) tách được: điểm (1,1,1) một phía, các điểm có tích 0 phía còn lại. Kernel tương ứng: $k(x,x') = (x^Tx' + 1)^2$ (polynomial bậc 2).

Kiểm chứng notebook: Linear SVM accuracy trên XOR = thấp (không tách được). Poly degree=2 accuracy = 1.0 (tách được hoàn toàn).

C6 – Bài toán đối ngẫu SVM lề mềm (dữ liệu C2)

Đề bài. Viết bài toán đối ngẫu của SVM lề mềm cho dữ liệu C2; chỉ ra dữ liệu chỉ xuất hiện dưới dạng tích vô hướng; giải thích vì sao điều đó cho phép dùng hàm nhân.

Primal (soft-margin):

$$\min_{w,b,\xi}\ \tfrac{1}{2}\|w\|^2 + C\sum_n \xi_n$$
$$\text{s.t. } y_n(w^Tx_n + b) \geq 1 - \xi_n,\ \xi_n \geq 0\ (n = 1, 2).$$

Đối ngẫu:

$$\max_\alpha\ \sum_n \alpha_n - \tfrac{1}{2}\sum_n\sum_m \alpha_n\alpha_m y_n y_m (x_n^T x_m)$$
$$\text{s.t. } 0 \leq \alpha_n \leq C,\ \sum_n \alpha_n y_n = 0.$$

Quan sát: dữ liệu x_n chỉ xuất hiện qua tích vô hướng $x_n^T x_m$.

Vì sao dùng được hàm nhân (hai câu): (1) Mọi chỗ $x_n^T x_m$ có thể thay bằng $k(x_n, x_m) = \varphi(x_n)^T \varphi(x_m)$ mà không cần tính φ tường minh. (2) Nhờ đó SVM làm việc trong không gian đặc trưng rất cao (thậm chí vô hạn chiều) chỉ với chi phí tính kernel trên không gian gốc.

Tóm tắt nhiệm vụ C

Mục	Kết luận chính (từ notebook)
C1	petal length + width; Setosa=+1 (50), rest=−1 (100)
C2	$w^*=(1/2,1/2)$, $b^*=0$, margin=$2\sqrt{2}\approx2.828$, cả 2 điểm là SV
C3	w → hướng + độ rộng lề; b → dịch song song biên
C4	C↑ ⇒ margin↓, #SV↓, #vi phạm↓ (0.01→100: margin 2.52→1.03)
C5	XOR: bao lồi giao nhau; $\varphi=(x_1,x_2,x_1x_2)$ tách được
C6	Đối ngẫu chỉ chứa $x_n^Tx_m$ → thay bằng kernel $k(x_n,x_m)$