MAI391 — TOÁN CHO HỌC MÁY

Computer Project — Nhóm 1

Hồi quy tuyến tính bằng hạ gradient

trên dữ liệu chất lượng rượu vang đỏ

Phạm vi kiến thức: Chương 7 (Tối ưu liên tục), Chương 9 (Hồi quy tuyến tính); công cụ bổ trợ từ Chương 4, 5.

---

1 Giới thiệu

Bài toán thực tế. Điểm chất lượng của rượu vang thường do chuyên gia nếm cho điểm, vừa tốn kém vừa chủ quan. Cortez và cộng sự [2] đặt câu hỏi: có thể dự đoán điểm cảm quan từ các phép đo hoá lý trong phòng thí nghiệm hay không? Báo cáo này giải bài toán đó cho rượu vang đỏ *vinho verde* (Bồ Đào Nha) bằng hồi quy tuyến tính, trong đó tham số được tìm *bằng thuật toán hạ gradient tự cài đặt từ đầu bằng numpy.*

Dữ liệu. Bộ *Wine Quality* của UCI Machine Learning Repository [3], tệp `winequality-red.csv`: 1599 mẫu, 11 đặc trưng số (độ axit cố định, độ axit bay hơi, axit citric, đường dư, clorua, SO_2 tự do, SO_2 tổng, tỉ trọng, pH, sunfat, nồng độ cồn) và nhãn `quality` (điểm nguyên từ 0 đến 10; trong dữ liệu chỉ có giá trị 3 đến 8). Dữ liệu không thiếu giá trị, giấy phép CC BY 4.0, DOI `10.24432/C56S3T`.

Vì sao chọn hạ gradient cho bài toán này. (i) Hạ gradient là nền tảng của việc huấn luyện hầu hết mô hình học máy. (ii) Bình phương tối thiểu có nghiệm đóng, nên ta có "đáp án chuẩn" để kiểm chứng chính xác lý thuyết hội tụ (điều kiện $\gamma < 2/\lambda_{\max}$, tốc độ theo số điều kiện κ). (iii) Các đặc trưng có thang đo chênh lệch rất lớn (ví dụ SO_2 tổng có độ lệch chuẩn ≈ 33, tỉ trọng chỉ $\approx 0{,}002$), nên đây là ví dụ tự nhiên cho vai trò của chuẩn hoá và điều kiện số.

Cấu trúc. Mục 2 trình bày nền tảng toán học; Mục 3 nêu cách cài đặt; Mục 4 là thực nghiệm; Mục 5 thảo luận; Mục 6 là tài liệu tham khảo và khai báo công cụ hỗ trợ.

2 Nền tảng toán học

2.1 Bài toán tối ưu từ hàm hợp lý Gauss (Chương 9)

Phần này theo cách trình bày của giáo trình [1] (Chương 4, 5, 7, 9). Cho tập huấn luyện $\{(\mathbf{x}_n, y_n)\}_{n=1}^{N}$ với $\mathbf{x}_n \in \mathbb{R}^D$, $y_n \in \mathbb{R}$ ($D = 11$). Đặt $\tilde{\mathbf{x}}_n = (1, \mathbf{x}_n^\top)^\top \in \mathbb{R}^{D+1}$ (thêm hệ số chặn) và giả sử mô hình

$$y_n = \tilde{\mathbf{x}}_n^\top \boldsymbol{\theta} + \varepsilon_n, \qquad \varepsilon_n \sim \mathcal{N}(0, \sigma^2) \text{ độc lập.} \tag{1}$$

Xếp các mẫu thành $\mathbf{X} \in \mathbb{R}^{N \times (D+1)}$ (hàng thứ n là $\tilde{\mathbf{x}}_n^\top$) và $\mathbf{y} \in \mathbb{R}^N$. Hàm hợp lý là $p(\mathbf{y} \mid \mathbf{X}, \boldsymbol{\theta}) = \prod_n \mathcal{N}(y_n \mid \tilde{\mathbf{x}}_n^\top \boldsymbol{\theta}, \sigma^2)$, nên

$$-\log p(\mathbf{y} \mid \mathbf{X}, \boldsymbol{\theta}) = \frac{1}{2\sigma^2} \left\| \mathbf{y} - \mathbf{X}\boldsymbol{\theta} \right\|^2 + \text{hằng số}.$$

Cực đại hoá hợp lý $\Leftrightarrow$ cực tiểu hoá tổng bình phương sai số; σ^2 chỉ là hệ số tỉ lệ dương và không đổi điểm cực tiểu. Chia thêm cho N để thang đo không phụ thuộc cỡ mẫu, ta giải

$$\min_{\boldsymbol{\theta} \in \mathbb{R}^{D+1}} \; L(\boldsymbol{\theta}), \qquad L(\boldsymbol{\theta}) = \frac{1}{2N} \left\| \mathbf{y} - \mathbf{X}\boldsymbol{\theta} \right\|^2 . \tag{2}$$

Bảng kích thước (kiểm tra tính nhất quán của mọi công thức bên dưới):

Đại lượng	Kích thước	Đại lượng	Kích thước
$\mathbf{X}$	$N \times (D+1)$	$\mathbf{H} = \frac{1}{N}\mathbf{X}^\top\mathbf{X}$	$(D+1) \times (D+1)$
$\mathbf{y}$, $\mathbf{X}\boldsymbol{\theta} - \mathbf{y}$	N	$\nabla L(\boldsymbol{\theta})$, $\boldsymbol{\theta}$, $\mathbf{v}$ (động lượng)	$D+1$
$\mathbf{X}^\top(\mathbf{X}\boldsymbol{\theta} - \mathbf{y})$	$(D+1) \times N \cdot N = D+1$	$\gamma, \beta, L(\boldsymbol{\theta})$	vô hướng

Bảng 1: Kích thước của các ma trận và vectơ (không đơn vị; $N = 1279$ mẫu huấn luyện, $D+1 = 12$).

2.2 Gradient, Hessian và tính lồi (Chương 5, 7)

Khai triển $L(\boldsymbol{\theta}) = \frac{1}{2N}(\mathbf{y}^\top\mathbf{y} - 2\boldsymbol{\theta}^\top\mathbf{X}^\top\mathbf{y} + \boldsymbol{\theta}^\top\mathbf{X}^\top\mathbf{X}\boldsymbol{\theta})$ và lấy đạo hàm theo vectơ:

$$\nabla L(\boldsymbol{\theta}) = \frac{1}{N}(\mathbf{X}^\top\mathbf{X}\boldsymbol{\theta} - \mathbf{X}^\top\mathbf{y}) = \frac{1}{N}\mathbf{X}^\top(\mathbf{X}\boldsymbol{\theta} - \mathbf{y}), \qquad \nabla^2 L(\boldsymbol{\theta}) = \mathbf{H} = \frac{1}{N}\mathbf{X}^\top\mathbf{X}. \tag{3}$$

Phép chuyển vị trong $\mathbf{X}^\top(\cdot)$ là bắt buộc để đưa vectơ dư N chiều về không gian tham số $(D+1)$ chiều.

Mệnh đề 1 (Tính lồi)**.** *L là hàm lồi. Nếu* $\operatorname{rank}\mathbf{X} = D+1$ *thì* $\mathbf{H} \succ 0$*, L lồi chặt và có đúng một điểm cực tiểu toàn cục.*

Chứng minh. Với mọi $\mathbf{v}$: $\mathbf{v}^\top\mathbf{H}\mathbf{v} = \frac{1}{N}\|\mathbf{X}\mathbf{v}\|^2 \geq 0$, nên $\mathbf{H} \succeq 0$ và L lồi. Dấu bằng chỉ xảy ra khi $\mathbf{X}\mathbf{v} = 0$, tức $\mathbf{v} \in \ker\mathbf{X} = \{0\}$ khi $\mathbf{X}$ đủ hạng cột. □

Giả thiết $\operatorname{rank}\mathbf{X} = D+1$ được kiểm chứng trên dữ liệu thật ở Mục 4.3.

Nghiệm đóng. Vì L lồi khả vi, $\boldsymbol{\theta}^*$ là cực tiểu $\Leftrightarrow \nabla L(\boldsymbol{\theta}^*) = 0$, tức phương trình chuẩn tắc $\mathbf{X}^\top\mathbf{X}\boldsymbol{\theta}^* = \mathbf{X}^\top\mathbf{y}$:

$$\boldsymbol{\theta}^* = \boldsymbol{\theta}_{\mathrm{ML}} = (\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top\mathbf{y}. \tag{4}$$

Ý nghĩa hình học: $\mathbf{X}^\top(\mathbf{y} - \mathbf{X}\boldsymbol{\theta}^*) = 0$, nghĩa là $\mathbf{X}\boldsymbol{\theta}^*$ là *hình chiếu trực giao* của $\mathbf{y}$ lên không gian cột của $\mathbf{X}$. Vì $\mathbf{H}\boldsymbol{\theta}^* = \frac{1}{N}\mathbf{X}^\top\mathbf{y}$, hàm mất mát là dạng toàn phương *đúng*:

$$L(\boldsymbol{\theta}) = L(\boldsymbol{\theta}^*) + \tfrac{1}{2}(\boldsymbol{\theta} - \boldsymbol{\theta}^*)^\top\mathbf{H}(\boldsymbol{\theta} - \boldsymbol{\theta}^*). \tag{5}$$

Nghiệm (4) dùng làm đáp án tham chiếu cho thuật toán lặp.

2.3 Hạ gradient và điều kiện hội tụ (Chương 7)

Theo hướng $-\nabla L$, hàm giảm nhanh nhất cục bộ. Với bước học $\gamma > 0$:

$$\boldsymbol{\theta}_{t+1} = \boldsymbol{\theta}_t - \gamma\nabla L(\boldsymbol{\theta}_t) = \boldsymbol{\theta}_t - \frac{\gamma}{N}\mathbf{X}^\top(\mathbf{X}\boldsymbol{\theta}_t - \mathbf{y}). \tag{6}$$

Gọi $\mu = \lambda_{\min}(\mathbf{H})$, $\ell = \lambda_{\max}(\mathbf{H})$ và số điều kiện $\kappa = \ell/\mu$ (với $\mu > 0$ theo Mệnh đề 1).

Định lý 1 (Hội tụ của hạ gradient trên bài toán bình phương tối thiểu)**.** *Dãy* (6) *hội tụ tới $\boldsymbol{\theta}^*$ với mọi $\boldsymbol{\theta}_0$ khi và chỉ khi $0 < \gamma < 2/\ell$. Khi đó $\|\boldsymbol{\theta}_t - \boldsymbol{\theta}^*\| \leq \rho(\gamma)^t\,\|\boldsymbol{\theta}_0 - \boldsymbol{\theta}^*\|$ với $\rho(\gamma) = \max\{|1-\gamma\mu|, |1-\gamma\ell|\}$. Bước học tối ưu là $\gamma_{\mathrm{opt}} = 2/(\ell+\mu)$, cho $\rho_{\mathrm{opt}} = \frac{\kappa-1}{\kappa+1}$; với $\gamma = 1/\ell$ thì $\rho = 1 - 1/\kappa$.*

Chứng minh. Đặt $\mathbf{e}_t = \boldsymbol{\theta}_t - \boldsymbol{\theta}^*$. Từ (3) và $\mathbf{H}\boldsymbol{\theta}^* = \frac{1}{N}\mathbf{X}^\top\mathbf{y}$ ta có $\nabla L(\boldsymbol{\theta}_t) = \mathbf{H}\mathbf{e}_t$, nên $\mathbf{e}_{t+1} = (\mathbf{I} - \gamma\mathbf{H})\mathbf{e}_t$, tức $\mathbf{e}_t = (\mathbf{I} - \gamma\mathbf{H})^t\mathbf{e}_0$. Vì $\mathbf{H}$ đối xứng, theo định lý phổ (Chương 4) $\mathbf{H} = \mathbf{Q}\Lambda\mathbf{Q}^\top$ với $\mathbf{Q}$ trực giao, và $\mathbf{Q}^\top\mathbf{e}_t = (\mathbf{I} - \gamma\Lambda)^t\mathbf{Q}^\top\mathbf{e}_0$: thành phần theo vectơ riêng thứ i bị nhân với $(1-\gamma\lambda_i)^t$. Hội tụ với mọi $\mathbf{e}_0 \Leftrightarrow |1-\gamma\lambda_i| < 1\ \forall i \Leftrightarrow 0 < \gamma < 2/\lambda_i\ \forall i \Leftrightarrow \gamma < 2/\ell$. Nếu $\gamma > 2/\ell$ thì $|1-\gamma\ell| > 1$ và thành phần theo vectơ riêng ứng với ℓ tăng theo cấp số nhân (phân kỳ).

Vì chuẩn ℓ_2 bất biến qua $\mathbf{Q}$, ta được cận ρ^t với $\rho = \max_i |1-\gamma\lambda_i| = \max\{|1-\gamma\mu|, |1-\gamma\ell|\}$ (hàm $|1-\gamma\lambda|$ lồi theo λ nên cực đại ở hai đầu mút). ρ nhỏ nhất khi $1-\gamma\mu = -(1-\gamma\ell)$, tức $\gamma = 2/(\ell+\mu)$, cho $\rho = \frac{\ell-\mu}{\ell+\mu} = \frac{\kappa-1}{\kappa+1}$. $\square$

Từ (5), $L(\boldsymbol{\theta}_t) - L(\boldsymbol{\theta}^*) = \frac{1}{2}\sum_i \lambda_i (1-\gamma\lambda_i)^{2t} c_i^2$ (c_i là toạ độ của $\mathbf{e}_0$), nên sai số hàm mất mát giảm với tốc độ ρ^2. Số vòng để giảm $\|\mathbf{e}\|$ từ $\|\mathbf{e}_0\|$ xuống ε là $t \geq \ln(\|\mathbf{e}_0\|/\varepsilon)/\ln(1/\rho) \approx \kappa \ln(\|\mathbf{e}_0\|/\varepsilon)$ khi $\gamma = 1/\ell$ (và $\approx \frac{\kappa}{2}\ln(\cdot)$ khi $\gamma = \gamma_{\text{opt}}$). **Kết luận quan trọng: tốc độ hội tụ do κ quyết định**, còn γ bị chặn bởi ℓ.

2.4 Chuẩn hoá đặc trưng và điều kiện số

Gọi $\mathbf{z} = (\mathbf{x} - \mathbf{m})/\mathbf{s}$ với $\mathbf{m}, \mathbf{s}$ là trung bình và độ lệch chuẩn *tính trên tập huấn luyện*. Khi đó $\mathbf{X} = [\mathbf{1} \;\; \mathbf{Z}]$ với $\mathbf{1}^\top \mathbf{Z} = 0$, nên

$$\mathbf{H} = \begin{pmatrix} 1 & \mathbf{0}^\top \\ \mathbf{0} & \mathbf{C} \end{pmatrix}, \qquad \mathbf{C} = \tfrac{1}{N}\mathbf{Z}^\top\mathbf{Z} \text{ là ma trận tương quan.}$$

Do $\operatorname{tr}\mathbf{H} = D+1$, mọi giá trị riêng nằm trong $[0, D+1]$, và κ chỉ còn phản ánh *đa cộng tuyến* giữa các đặc trưng. Ngược lại với dữ liệu thô, trung bình lớn (ví dụ SO_2 tổng ≈ 47) đẩy $\lambda_{\max}$ lên rất cao, còn các hướng như tỉ trọng (độ lệch chuẩn 0,002) cho $\lambda_{\min}$ cực nhỏ; $\gamma < 2/\lambda_{\max}$ khiến bước học nhỏ, đồng thời κ khổng lồ khiến hội tụ chậm đến mức không dùng được. Hồi quy trên $\mathbf{Z}$ và trên $\mathbf{x}$ cùng một lớp mô hình (affine), nên giá trị cực tiểu của L và sai số dự đoán tối ưu là như nhau; chỉ *đường đi* của thuật toán khác nhau.

2.5 Quán tính (momentum) kiểu heavy-ball

Thêm động lượng $\mathbf{v}_t$: $\mathbf{v}_{t+1} = \beta\mathbf{v}_t - \gamma\nabla L(\boldsymbol{\theta}_t)$, $\boldsymbol{\theta}_{t+1} = \boldsymbol{\theta}_t + \mathbf{v}_{t+1}$ ($\beta \in [0,1)$; $\beta = 0$ trở về (6)). Trên dạng toàn phương, theo từng vectơ riêng ứng với λ: $e_{t+1} = (1+\beta-\gamma\lambda)e_t - \beta e_{t-1}$, với đa thức đặc trưng $z^2 - (1+\beta-\gamma\lambda)z + \beta = 0$. Nếu $(1+\beta-\gamma\lambda)^2 \leq 4\beta$, hai nghiệm là phức liên hợp có mô-đun $\sqrt{\beta}$, tức e_t co về 0 với tốc độ $\sqrt{\beta}$ *không phụ thuộc* λ. Điều kiện này tương đương $(1-\sqrt{\beta})^2 \leq \gamma\lambda \leq (1+\sqrt{\beta})^2$. Chọn γ, β sao cho khoảng này trùng với $[\gamma\mu, \gamma\ell]$:

$$\gamma = \frac{4}{(\sqrt{\ell}+\sqrt{\mu})^2}, \qquad \beta = \Big(\frac{\sqrt{\kappa}-1}{\sqrt{\kappa}+1}\Big)^2, \qquad \text{tốc độ } \sqrt{\beta} = \frac{\sqrt{\kappa}-1}{\sqrt{\kappa}+1} \approx 1 - \frac{2}{\sqrt{\kappa}}. \tag{7}$$

Lưu ý: Định lý 1 chỉ áp dụng cho $\beta = 0$. Khi có quán tính, các nghiệm của đa thức đặc trưng có mô-đun nhỏ hơn 1 với mọi $\lambda \in [\mu, \ell]$ khi và chỉ khi $0 \leq \beta < 1$ và $0 < \gamma < 2(1+\beta)/\ell$, nên γ được phép lớn hơn $2/\ell$. Chẳng hạn tham số tối ưu (7) trên dữ liệu của nhóm cho $\gamma \approx 0{,}9995 > \gamma_{\max} = 0{,}6485$ nhưng vẫn hội tụ vì $2(1+\beta)/\ell \approx 1{,}019$.

Như vậy quán tính thay κ bằng $\sqrt{\kappa}$ trong số vòng lặp cần thiết (Polyak [4]). Với $\kappa = 51{,}6$: $\sqrt{\beta} \approx 0{,}756$ so với $\rho_{\text{opt}} \approx 0{,}962$ của hạ gradient thường.

2.6 Liên hệ với các chương đã học

Khái niệm	Chương	Vai trò trong bài
Hợp lý Gauss, ML	9	Sinh ra hàm mất mát (2) từ giả thiết nhiễu Gauss
Phương trình chuẩn tắc, hình chiếu trực giao	9	Nghiệm tham chiếu $\boldsymbol{\theta}^*$ (4) để kiểm chứng GD
Đạo hàm theo vectơ, gradient	5	Công thức (3)
Hàm lồi, Hessian nửa xác định dương	7	Chứng minh cực tiểu toàn cục duy nhất (Mệnh đề 1)
Hạ gradient, bước học	7	Thuật toán (6), điều kiện $\gamma < 2/\ell$ (Định lý 1)
Định lý phổ, giá trị riêng, chéo hoá	4	Phân tích sai số theo từng hướng riêng; κ
Quán tính	7	Tăng tốc, tốc độ $\sqrt{\beta}$ theo (7)

Bảng 2: Công cụ toán học và vị trí sử dụng (bảng định tính, không có đơn vị).

3 Cài đặt

Mã nguồn nằm trong `src/`: `gd_linreg.py` (lõi, chỉ dùng NumPy [5]), `test_core.py` (7 kiểm thử theo thứ tự tăng dần), `run_experiments.py` (toàn bộ thực nghiệm, bảng, hình) và notebook `CP_Nhom1_GD_LinReg.ipynb` (cùng nội dung, có giải thích từng bước). Thư viện `scikit-learn` [6] chỉ được gọi trong `run_experiments.py` để đối chiếu.

Thuật toán 1 (hạ gradient có quán tính; $\beta = 0$ là GD thường). **Vào:** $\mathbf{X} \in \mathbb{R}^{N\times(D+1)}$, $\mathbf{y} \in \mathbb{R}^N$, γ, β, T, ε. **Ra:** $\boldsymbol{\theta}$.
1. $\boldsymbol{\theta} \leftarrow \mathbf{0}$, $\mathbf{v} \leftarrow \mathbf{0}$ 2. **lặp** $t = 1, \dots, T$:
3. $\mathbf{g} \leftarrow \frac{1}{N}\mathbf{X}^\top(\mathbf{X}\boldsymbol{\theta} - \mathbf{y})$ 4. nếu $\|\mathbf{g}\| < \varepsilon$ thì dừng
5. $\mathbf{v} \leftarrow \beta\mathbf{v} - \gamma\mathbf{g}$ 6. $\boldsymbol{\theta} \leftarrow \boldsymbol{\theta} + \mathbf{v}$ 7. nếu $L(\boldsymbol{\theta})$ không hữu hạn hoặc $> 10^{30}$ thì dừng (phân kỳ)

Ghi chú về tiêu chí dừng. Điều kiện $\|\mathbf{g}\| < \varepsilon$ là tiêu chí thực hành (không cần biết $\boldsymbol{\theta}^*$). Trong thực nghiệm, thuật toán chạy số vòng cố định T; các bảng đếm số vòng đến khi $\|\boldsymbol{\theta}_t - \boldsymbol{\theta}^*\| < 10^{-6}$ là đại lượng cần $\boldsymbol{\theta}^*$ nên chỉ dùng để *đo* tốc độ hội tụ, không phải tiêu chí dừng của thuật toán. Hai tiêu chí liên hệ qua $\|\mathbf{g}\| = \|\mathbf{H}\mathbf{e}\| \geq \lambda_{\min}\|\mathbf{e}\|$, tức $\|\boldsymbol{\theta} - \boldsymbol{\theta}^*\| \leq \|\mathbf{g}\|/\lambda_{\min}$; kiểm tra số với $\varepsilon = 10^{-5}$: $\|\mathbf{g}\| = 9{,}81 \times 10^{-6}$, $\|\boldsymbol{\theta} - \boldsymbol{\theta}^*\| = 1{,}64 \times 10^{-4}$ và $\|\mathbf{g}\|/\lambda_{\min} = 1{,}64 \times 10^{-4}$.

Các quyết định cài đặt.

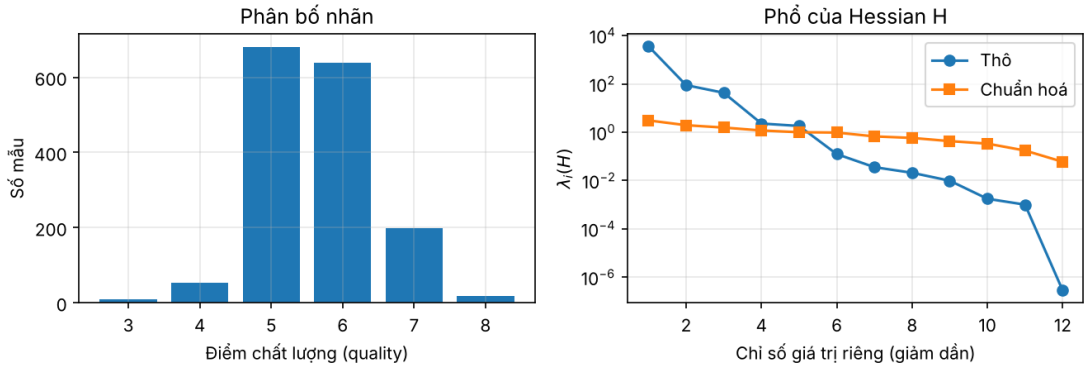
- Thêm cột $\mathbf{1}$ vào $\mathbf{X}$ để học hệ số chặn cùng các hệ số khác; không điều chuẩn hệ số chặn.
- Thống kê chuẩn hoá $(\mathbf{m}, \mathbf{s})$ chỉ tính trên tập huấn luyện rồi áp cho tập kiểm tra, tránh rò rỉ thông tin.
- $\lambda_{\max}, \lambda_{\min}$ lấy từ `np.linalg.eigvalsh`($\mathbf{H}$) (ma trận đối xứng), dùng để đặt γ theo Định lý 1. Nghiệm đóng giải bằng `np.linalg.solve` thay vì nghịch đảo tường minh (ổn định số hơn).
- Mã vector hoá hoàn toàn (hai phép nhân ma trận–vectơ mỗi vòng); số học `float64`; có chặn phân kỳ để thí nghiệm $\gamma > 2/\lambda_{\max}$ không gây tràn số.
- Tái lập: có ba nguồn ngẫu nhiên, đều cố định hạt giống. (i) Chia dữ liệu: `np.random.default_rng(42).per` 320 phần tử *đầu* là tập kiểm tra, 1279 phần tử còn lại là tập huấn luyện (lấy 20% *cuối* làm tập kiểm tra cho MSE kiểm tra 0,359 thay vì 0,402). (ii) Kiểm tra gradient: $\boldsymbol{\theta} \sim \mathcal{N}(0, \mathbf{I})$ từ `default_rng(0)`. (iii) Dữ liệu tổng hợp: `default_rng(42)`, cấu hình ở Mục 4.2. Hạ gradient không có yếu tố ngẫu nhiên ($\boldsymbol{\theta}_0 = \mathbf{0}$, $\mathbf{v}_0 = \mathbf{0}$).

Độ phức tạp. Mỗi vòng lặp tốn hai phép nhân ma trận–vectơ: $O(N(D+1))$ thời gian, $O(ND)$ bộ nhớ; tổng $O(TND)$. (Có thể tính trước $\mathbf{H}$ và $\mathbf{b} = \frac{1}{N}\mathbf{X}^\top\mathbf{y}$ để mỗi vòng chỉ tốn $O(D^2)$, vì $\nabla L = \mathbf{H}\boldsymbol{\theta} - \mathbf{b}$; nhóm giữ dạng (3) cho trực tiếp.) Nghiệm chuẩn tắc tốn $O(ND^2 + D^3)$. Với $D = 11$ nghiệm đóng rẻ hơn; hạ gradient có lợi khi D rất lớn hoặc dữ liệu đến theo luồng.

4 Thực nghiệm

4.1 Dữ liệu, chia dữ liệu, chỉ số

Hoán vị ngẫu nhiên 1599 mẫu với hạt giống 42, lấy 20% làm tập kiểm tra: 1279 mẫu huấn luyện, 320 mẫu kiểm tra. Chỉ số: sai số bình phương trung bình MSE $= \frac{1}{n}\sum(y_i - \hat{y}_i)^2$ $(= 2L)$, hệ số xác định R^2 trên tập kiểm tra, $\|\cdot\|_\infty$ giữa các vectơ tham số, và số vòng lặp để $\|\boldsymbol{\theta}_t - \boldsymbol{\theta}^*\| < 10^{-6}$. Mốc so sánh: dự đoán bằng trung bình nhãn huấn luyện cho MSE kiểm tra $= 0{,}6040$.



Hình 1: Trái: phân bố nhãn `quality` (số mẫu theo điểm), lệch mạnh về 5 và 6. Phải: phổ giá trị riêng của $\mathbf{H}$ (trục y log) với dữ liệu thô và đã chuẩn hoá.

4.2 Kiểm thử theo thứ tự tăng dần

Bảy kiểm thử trong `test_core.py` đều đạt; ba nhóm chính theo thứ tự của đề:

1. *Ví dụ nhỏ giải tay.* Bốn điểm $(x, y) = (0,1), (1,3), (2,4), (3,8)$, $\mathbf{X}$ có cột đầu toàn 1. Giải tay: $N = 4$, $\sum x = 6$, $\sum x^2 = 14$, $\sum y = 16$, $\sum xy = 35$, nên $\begin{pmatrix} 4 & 6 \\ 6 & 14 \end{pmatrix}\begin{pmatrix} b \\ w \end{pmatrix} = \begin{pmatrix} 16 \\ 35 \end{pmatrix}$, $\det = 20$, $b = \frac{14\cdot16 - 6\cdot35}{20} = 0{,}7$, $w = \frac{4\cdot35 - 6\cdot16}{20} = 2{,}2$, tức $\hat{y} = 0{,}7 + 2{,}2x$. Hạ gradient với $\gamma = 1/\lambda_{\max}$ ($\lambda_{\max} = 4{,}20$, $\lambda_{\min} = 0{,}297$), 5000 vòng, lệch đáp số giải tay tối đa $1{,}6 \times 10^{-15}$. Với $\gamma > 2/\lambda_{\max}$ thuật toán phân kỳ, và heavy-ball cũng hội tụ về đáp số này.
2. *Kiểm tra gradient.* So (3) với sai phân hữu hạn trung tâm (bước 10^{-5}) tại $\boldsymbol{\theta} \sim \mathcal{N}(0, \mathbf{I})$ sinh bởi `default_rng(0)`, trên dữ liệu huấn luyện đã chuẩn hoá: sai khác lớn nhất $3{,}2 \times 10^{-10}$.
3. *Dữ liệu tổng hợp.* `rng = default_rng(42)`, sinh *theo thứ tự*: $\mathbf{X} \sim \mathcal{N}(0,1)$ cỡ 500×11 (thêm cột 1), $\boldsymbol{\theta}_{\text{true}} \sim \mathcal{N}(0,1)$ gồm 12 phần tử, nhiễu $\mathcal{N}(0, 0{,}05^2)$ cỡ 500; $\mathbf{y} = \mathbf{X}\boldsymbol{\theta}_{\text{true}} + \text{nhiễu}$. Hạ gradient (20 000 vòng) trùng nghiệm chuẩn tắc đến $8{,}9 \times 10^{-16}$; nghiệm chuẩn tắc lệch $\boldsymbol{\theta}_{\text{true}}$ tối đa 0,0037, cùng bậc với sai số thống kê do nhiễu lấy mẫu ($\sigma/\sqrt{N} \approx 0{,}0022$) chứ không phải lỗi thuật toán.

Sau đó mới chạy trên dữ liệu thật (các mục sau).

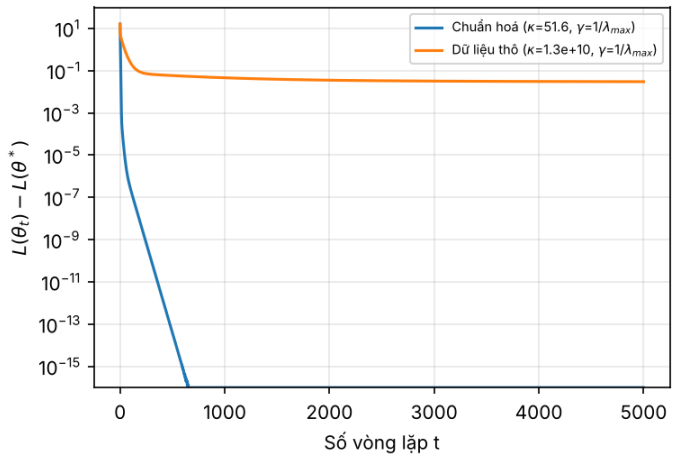
4.3 Điều kiện số: dữ liệu thô và dữ liệu chuẩn hoá

Dữ liệu	$\lambda_{\max}$	$\lambda_{\min}$	κ	$\gamma_{\max} = 2/\lambda_{\max}$
Thô	$3{,}63 \times 10^{3}$	$2{,}82 \times 10^{-7}$	$1{,}29 \times 10^{10}$	$5{,}51 \times 10^{-4}$
Chuẩn hoá	3,084	0,0597	51,6	0,6485

Bảng 3: Phổ của $\mathbf{H}$ trên tập huấn luyện (không đơn vị). Chuẩn hoá giảm κ khoảng $2{,}5 \times 10^{8}$ lần.

Giả thiết hạng đầy đủ của Mệnh đề 1 thoả trên dữ liệu: $\lambda_{\min} = 0{,}0597 > 0$ và hạng của $\mathbf{X}$ (tính bằng NumPy) bằng $12 = D + 1$.

Với $\gamma = 1/\lambda_{\max}$ và $T = 5000$ vòng: trên dữ liệu chuẩn hoá, $\|\boldsymbol{\theta}_t - \boldsymbol{\theta}^*\| < 10^{-6}$ sau 507 vòng; trên dữ liệu thô, sai số hàm mất mát vẫn còn 0,030, $\|\boldsymbol{\theta}_T - \boldsymbol{\theta}^*\| \approx 57{,}4$ và MSE kiểm tra là 0,5001 (so với 0,4018 ở nghiệm tối ưu). Cận lý thuyết $\kappa \ln(\cdot)$ cho dữ liệu thô cỡ 10^{11} vòng, tức là thực tế không hội tụ (Hình 2).



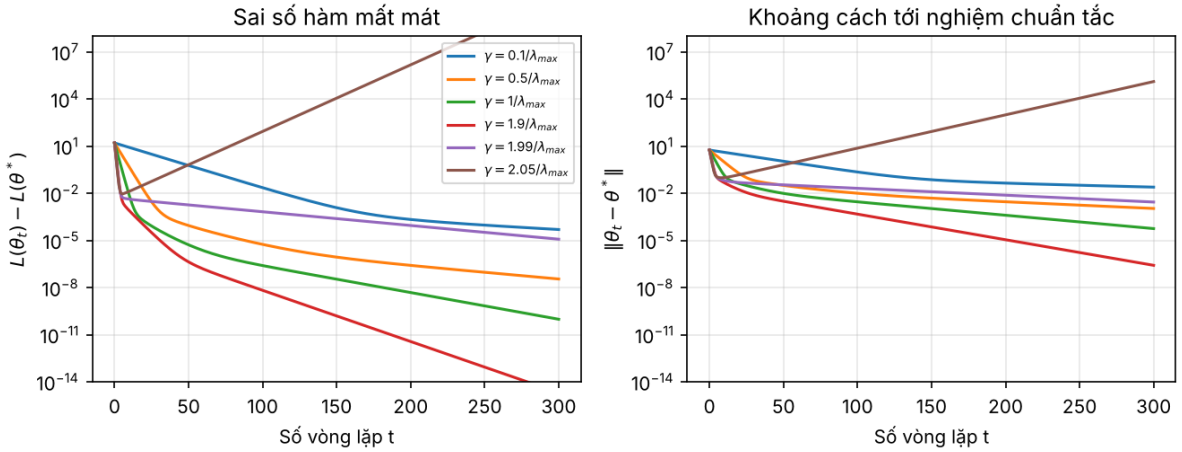
Hình 2: Sai số hàm mất mát $L(\boldsymbol{\theta}_t) - L(\boldsymbol{\theta}^*)$ theo số vòng lặp, $\gamma = 1/\lambda_{\max}$, dữ liệu chuẩn hoá và dữ liệu thô. Trục y cắt ở 10^{-16} (độ chính xác máy).

4.4 Khảo sát bước học γ (dữ liệu chuẩn hoá)

Đặt $\gamma = c/\lambda_{\max}$ với $c \in \{0{,}1; 0{,}5; 1; 1{,}9; 1{,}99; 2{,}05\}$, tức $\gamma/\gamma_{\max} = c/2$.

γ	$\gamma/\gamma_{\max}$	Giá trị γ	$L(\boldsymbol{\theta}_{300})$	Số vòng đến $\|\boldsymbol{\theta}_t - \boldsymbol{\theta}^*\| < 10^{-6}$
$0{,}1/\lambda_{\max}$	0,05	0,0324	0,211270	5114
$0{,}5/\lambda_{\max}$	0,25	0,1621	0,211221	1019
$1{,}0/\lambda_{\max}$	0,50	0,3243	0,211220	507
$1{,}9/\lambda_{\max}$	0,95	0,6161	0,211220	265
$1{,}99/\lambda_{\max}$	0,995	0,6453	0,211233	1090
$2{,}05/\lambda_{\max}$	1,025	0,6647	phân kỳ	—

Bảng 4: Ảnh hưởng của bước học. Cột cuối tính bằng vòng lặp; γ và L không đơn vị ($L(\boldsymbol{\theta}^*) = 0{,}2112205$).



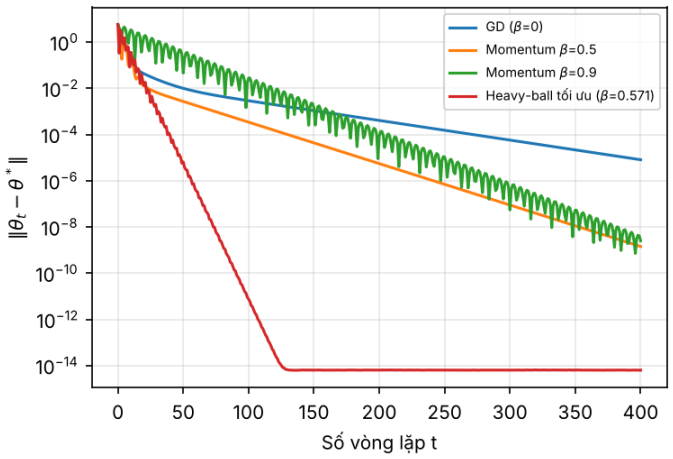
Hình 3: Hạ gradient với các bước học khác nhau. Trái: $L(\boldsymbol{\theta}_t) - L(\boldsymbol{\theta}^*)$. Phải: $\|\boldsymbol{\theta}_t - \boldsymbol{\theta}^*\|$. Bước $\gamma > 2/\lambda_{\max}$ phân kỳ; bước gần $2/\lambda_{\max}$ hội tụ rất chậm.

Kết quả khớp Định lý 1: $\gamma = 2{,}05/\lambda_{\max} > 2/\lambda_{\max}$ phân kỳ (đường nâu); $\gamma = 1{,}99/\lambda_{\max}$ vẫn hội tụ nhưng rất chậm vì $\rho = |1 - \gamma\lambda_{\max}| \approx 0{,}99$; bước quá nhỏ cũng chậm vì $\rho = 1 - \gamma\mu$ gần 1. Với bước tối ưu lý thuyết $\gamma_{\text{opt}} = 2/(\lambda_{\max} + \lambda_{\min}) = 0{,}6362$ $(= 0{,}981\,\gamma_{\max})$, $\rho_{\text{opt}} = 0{,}9620$, cận lý thuyết là khoảng 401 vòng, thực đo 285 vòng. Cận cho $\gamma = 1/\lambda_{\max}$ là khoảng 803 vòng (với $\|\boldsymbol{\theta}_0 - \boldsymbol{\theta}^*\| = \|\boldsymbol{\theta}^*\| = 5{,}67$), thực đo 507 vòng. Đây là cận xấu nhất nên thực đo luôn nhỏ hơn hoặc bằng. Lưu ý cận chỉ là cận trên, nên $c = 1{,}9$ (265 vòng) có thể nhanh hơn một chút so với γ_{opt} trên đúng điểm khởi tạo này vì thành phần sai số ban đầu theo từng hướng riêng không đều.

4.5 Khảo sát quán tính

Cấu hình	γ	β	Vòng đến $\|\boldsymbol{\theta}_t - \boldsymbol{\theta}^*\| < 10^{-6}$
GD thường ($\beta = 0$, $\gamma = 1/\lambda_{\max}$)	0,3243	0,000	>400 (507)
Momentum ($\beta = 0{,}5$, $\gamma = 1/\lambda_{\max}$)	0,3243	0,500	242
Momentum ($\beta = 0{,}9$, $\gamma = 1/\lambda_{\max}$)	0,3243	0,900	263
Heavy-ball tối ưu (công thức Polyak)	0,9995	0,571	57

Bảng 5: Ảnh hưởng của động lượng (cột cuối tính bằng vòng lặp, chạy tối đa 400 vòng; γ, β không đơn vị).



Hình 4: $\|\boldsymbol{\theta}_t - \boldsymbol{\theta}^*\|$ theo vòng lặp với các giá trị β. Tham số heavy-ball tối ưu (7) nhanh hơn rõ rệt; $\beta = 0{,}9$ dao động mạnh.

Ước lượng tiệm cận theo tốc độ $\sqrt{\beta}$ cho heavy-ball tối ưu là khoảng 56 vòng (đây là *ước lượng*, không phải cận chặt: với tham số tối ưu, hai giá trị riêng cực trị nằm đúng mép khoảng nên nghiệm đặc trưng là nghiệm kép, sinh thêm thừa số dạng $(1+t)$ và số vòng thực tế nhỉnh hơn một chút), thực đo 57 vòng, nhanh gấp khoảng 9 lần so với GD ($\gamma = 1/\lambda_{\max}$) và khớp với dự đoán $\kappa \to \sqrt{\kappa}$. Kiểm tra số trên cả 12 giá trị riêng: môđun nghiệm đặc trưng của heavy-ball tối ưu đều bằng $\sqrt{\beta} = 0{,}755665$, và biệt thức $(1+\beta-\gamma\lambda)^2 - 4\beta$ bằng 0 tại $\lambda_{\min}$ và $\approx -4\times10^{-15}$ tại $\lambda_{\max}$ (nghiệm kép ở hai mép, đúng như giải thích ở trên). Với $\gamma = 1/\lambda_{\max}$, $\beta = 0{,}5$ có nghiệm phức ở 10/12 giá trị riêng còn $\beta = 0{,}9$ ở cả 12/12, phù hợp với đường cong dao động (không đơn điệu) của $\beta = 0{,}9$.

4.6 So sánh với thư viện chuẩn

Phương pháp	MSE huấn luyện	MSE kiểm tra	R^2 kiểm tra	$\|\boldsymbol{\theta} - \boldsymbol{\theta}^*\|_\infty$
Nghiệm chuẩn tắc (numpy, (4))	0,4224	0,4018	0,3208	0
Hạ gradient (2000 vòng, $\gamma = 1/\lambda_{\max}$)	0,4224	0,4018	0,3208	$3{,}7\times10^{-15}$
Heavy-ball (2000 vòng)	—	—	—	$4{,}0\times10^{-15}$
`sklearn LinearRegression` [6]	—	0,4018	0,3208	$4{,}2\times10^{-15}$

Bảng 6: So sánh trên cùng phép chia dữ liệu, cùng chuẩn hoá. MSE tính theo thang điểm [2].

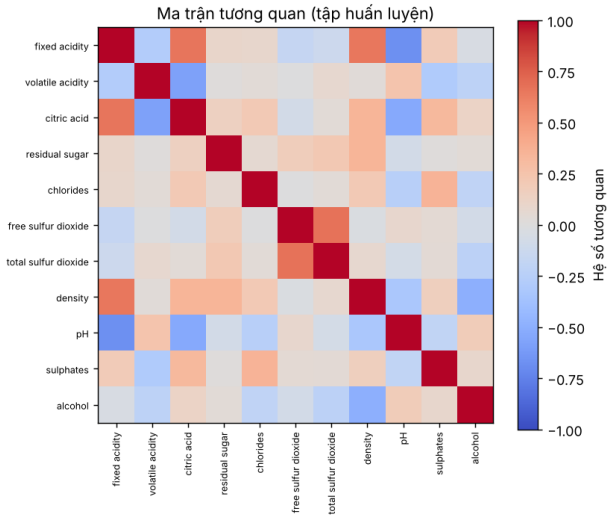
Mọi phương pháp cho cùng nghiệm đến cỡ sai số máy ($\sim 10^{-15}$), và hạ gradient trùng `scikit-learn` đến $8{,}9\times10^{-16}$. Không có sai khác đáng kể cần giải thích; điều này xác nhận cả công thức gradient lẫn điều kiện hội tụ trong Mục 2.

5 Thảo luận

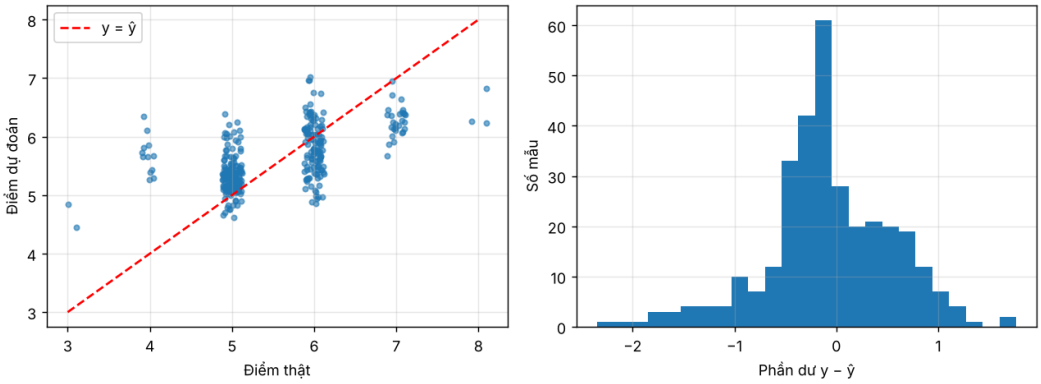
Thuật toán tốt ở đâu. Hạ gradient hội tụ đúng như lý thuyết dự đoán khi dữ liệu được chuẩn hoá ($\kappa \approx 51{,}6$): bước học $\gamma < 2/\lambda_{\max}$ đủ để hội tụ, số vòng lặp tỉ lệ với κ, và quán tính rút xuống tỉ lệ với $\sqrt{\kappa}$. Ba cách giải (nghiệm đóng, hạ gradient, `scikit-learn`) trùng nhau, nên sai số dự đoán không đến từ thuật toán tối ưu.

Thuật toán kém ở đâu và vì sao.

- *Dữ liệu thô*: $\kappa \sim 10^{10}$ làm hạ gradient gần như đứng yên (Hình 2). Chuẩn hoá là điều kiện cần trong thực hành.
- *Chọn* γ: sát $2/\lambda_{\max}$ thì chậm, vượt thì phân kỳ; trên dữ liệu lớn việc tính $\lambda_{\max}$ cần thêm chi phí (ví dụ phương pháp luỹ thừa).
- *Chất lượng dự đoán khiêm tốn*: $R^2 \approx 0{,}3208$ (RMSE $\approx 0{,}634$ điểm, so với độ lệch chuẩn nhãn $\approx 0{,}81$). Bằng chứng từ thực nghiệm: (i) dự đoán bị *co về trung bình*: dự đoán trung bình cho nhãn 5, 6, 7 lần lượt là 5,33; 5,82; 6,26 (đúng chiều nhưng bị nén, Hình 6); nhãn 3 và 8 chỉ có 2 và 3 mẫu trong tập kiểm tra nên nhóm không suy diễn từ chúng; phần dư có trung bình $-0{,}079$ và độ lệch chuẩn 0,629; (ii) thêm đặc trưng bậc hai (77 đặc trưng gồm x_i và $x_i x_j$, $i \le j$, cùng nghiệm chuẩn tắc) chỉ đưa MSE kiểm tra từ 0,4018 xuống 0,3924 và R^2 từ 0,3208 lên 0,337 (MSE huấn luyện 0,3699, hơi quá khớp), tức phi tuyến bậc hai giải thích được một phần nhỏ; (iii) tuy R^2 thấp, làm tròn dự đoán thì đoán đúng điểm 63,1% và sai lệch không quá 1 điểm 96,6%, hơn hẳn mốc luôn đoán 5 (46,6%) hoặc luôn đoán 6 (39,4%). Điều này gợi ý phần sai số còn lại nhiều khả năng đến từ tính chủ quan và tính thứ bậc, mất cân bằng của nhãn (hơn 80% là 5 hoặc 6, trái với giả thiết nhiễu Gauss liên tục của (1)), nhưng nhóm chưa có thí nghiệm riêng kiểm chứng điểm này. Đây là hạn chế của *mô hình*, không phải của hạ gradient.
- *Đa cộng tuyến*: $\lambda_{\min} = 0{,}0597$ nhỏ do các đặc trưng tương quan (Hình 5). Trên tập huấn luyện, tỉ trọng tương quan $+0{,}652$ với độ axit cố định và $-0{,}497$ với cồn; độ axit cố định tương quan $-0{,}679$ với pH và $+0{,}663$ với axit citric. Hệ số lạm phát phương sai (VIF) cao nhất: độ axit cố định 7,69, tỉ trọng 6,37, pH 3,28, axit citric 3,17. Vì vậy κ còn cỡ 50 ngay cả sau chuẩn hoá và các hệ số riêng lẻ kém ổn định.



Hình 5: Ma trận tương quan của 11 đặc trưng trên tập huấn luyện (hệ số tương quan, không đơn vị).



Hình 6: Tập kiểm tra. Trái: điểm dự đoán theo điểm thật (điểm thật có thêm nhiễu ngang nhỏ để dễ nhìn; đường đứt là $y = \hat{y}$). Phải: phân bố phần dư $y - \hat{y}$ (đơn vị: điểm).

Diễn giải hệ số. Với đặc trưng đã chuẩn hoá, các hệ số lớn nhất là cồn (+0,289), độ axit bay hơi (−0,198), sunfat (+0,148), độ axit cố định (+0,115) và SO_2 tổng (−0,102): rượu nhiều cồn, ít axit bay hơi và nhiều sunfat được chấm điểm cao hơn. Đây là tương quan trong dữ liệu quan sát, không phải quan hệ nhân quả.

Hạn chế và hướng mở rộng. (i) Chỉ một phép chia train/test; có thể thêm kiểm tra chéo. (ii) Mới khảo sát hạ gradient toàn bộ; có thể mở rộng sang hạ gradient ngẫu nhiên (mini-batch), tìm kiếm đường thẳng, hay gia tốc Nesterov. (iii) Thêm điều chuẩn ℓ_2 (hồi quy Ridge, hồi quy MAP) vừa giảm κ (các giá trị riêng dịch lên $\lambda_i + \alpha$) vừa giảm quá khớp. (iv) Dùng ánh xạ đặc trưng đa thức hoặc coi bài toán là phân loại thứ bậc để cải thiện độ chính xác.

6 Tài liệu tham khảo và khai báo công cụ hỗ trợ

Danh mục tài liệu tham khảo

[1] M. P. Deisenroth, A. A. Faisal, C. S. Ong. *Mathematics for Machine Learning*. Cambridge University Press, 2020 (Chương 4, 5, 7, 9).

[2] P. Cortez, A. Cerdeira, F. Almeida, T. Matos, J. Reis. Modeling wine preferences by data mining from physicochemical properties. *Decision Support Systems*, 47(4):547–553, 2009. DOI: 10.1016/j.dss.2009.05.016.

[3] P. Cortez, A. Cerdeira, F. Almeida, T. Matos, J. Reis. *Wine Quality* [Dataset]. UCI Machine Learning Repository, 2009. `https://doi.org/10.24432/C56S3T`; `https://archive.ics.uci.edu/dataset/186/wine+quality`.

[4] B. T. Polyak. Some methods of speeding up the convergence of iteration methods. *USSR Computational Mathematics and Mathematical Physics*, 4(5):1–17, 1964.

[5] C. R. Harris et al. Array programming with NumPy. *Nature*, 585:357–362, 2020.

[6] F. Pedregosa et al. Scikit-learn: Machine learning in Python. *JMLR*, 12:2825–2830, 2011 (chỉ dùng để đối chiếu).

Khai báo công cụ hỗ trợ. Nhóm sử dụng trợ lý AI **Claude** (Anthropic) để hỗ trợ soạn thảo báo cáo và viết, kiểm thử mã nguồn. Toàn bộ số liệu, bảng và hình trong báo cáo được sinh trực tiếp từ `src/run_experiments.py` với hạt giống cố định, nên có thể chạy lại để kiểm chứng. Các thành viên đã đọc, kiểm tra và chịu trách nhiệm giải thích mọi công thức và mọi dòng mã nộp kèm.